PROJET DE DATA MINING ET NLP

Sujet 4 : Détection des émotions dans les textes en langues arabes

De la collecte Web à la préparation d'un corpus exploitable

Question (partie 3)
Variation des émotions en fonction de quoi ?
Du thème abordé : sport, économie, politique, religion, technologie et santé.

Talel Mdalla Adem Sghaier Aziz Oueslati

31 octobre 2026

Compréhension métier : le besoin

Le problème

Les réactions publiées en arabe sur le Web sont nombreuses et touchent des sujets variés. Leur lecture manuelle rend les comparaisons lentes et difficiles à reproduire.

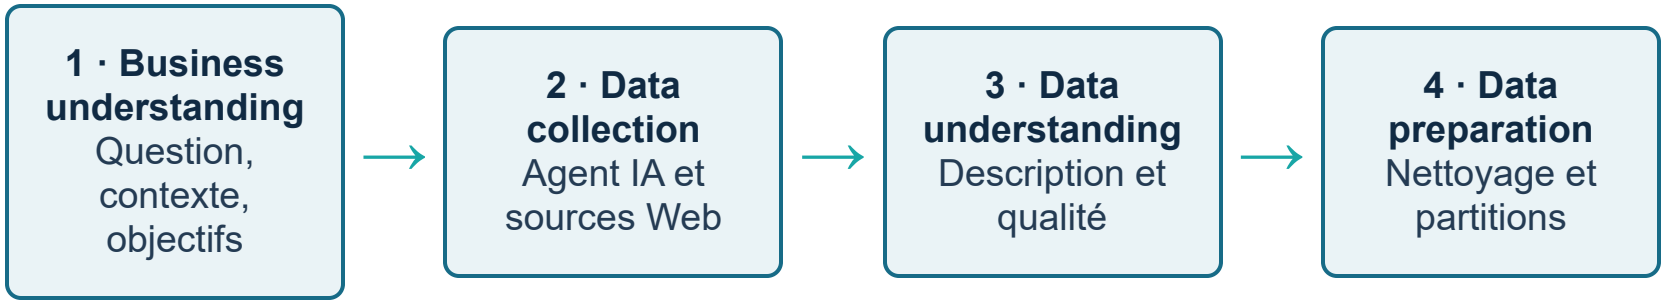
> **Question de recherche**
> Comment les émotions exprimées dans le corpus varient-elles selon le thème abordé ?

Objectifs

1. Collecter et structurer des textes arabes.
2. Décrire thèmes et émotions.
3. Nettoyer et partitionner le corpus.
4. Préparer une base pour une future classification NLP.

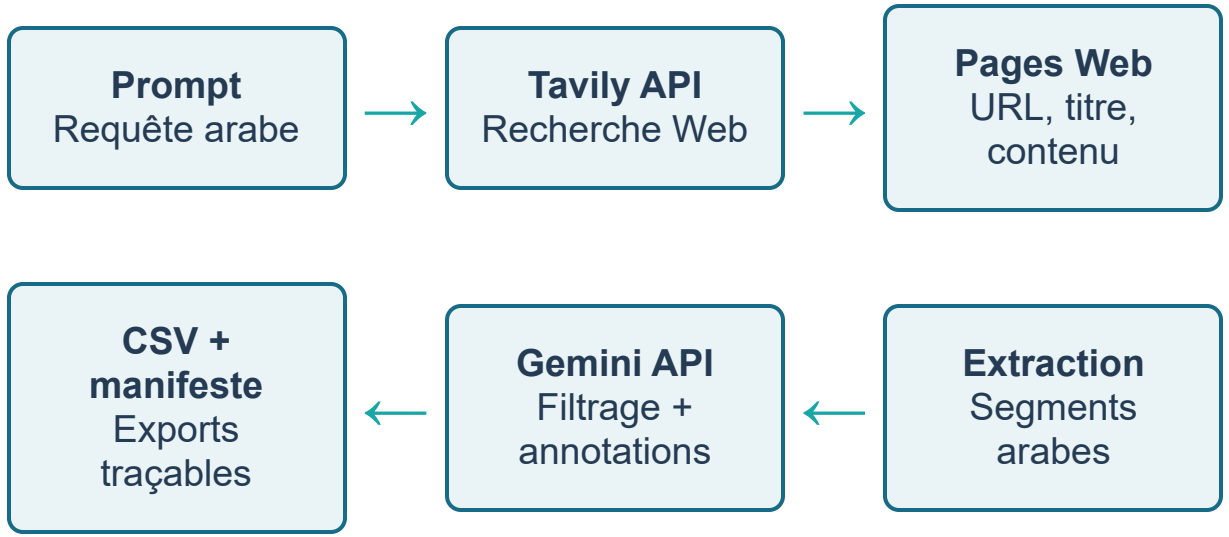
Fouille de données : résumer les volumes aujourd'hui · **Machine learning** : classer de nouveaux textes demain.

Plan de travail : quatre phases liées



Chaque phase transforme la question métier en données structurées et prêtes pour l'analyse.

L'agent IA : de la requête aux données



Tavily
Recherche de pages publiques, jusqu'à 10 résultats en arabe avec ciblage Tunisie.

Gemini
Filtre la pertinence et propose un thème et une émotion structurés.

Les clés API sont chargées depuis AI_agent/.env; elles ne sont pas intégrées au dépôt Git.

Collecte : extraire, filtrer, enrichir

Traitement des pages

1. Lire le contenu brut disponible.
2. Retirer le balisage et les liens.
3. Segmenter le texte.
4. Garder les segments arabes d'au moins 25 caractères.
5. Écarter les répétitions exactes.
6. Faire annoter les textes pertinents.

Schéma du CSV

Champ	Rôle
id	Identifiant de l'observation
text	Segment arabe extrait
topic	6 thèmes autorisés
emotion	5 émotions autorisées

Le manifeste relie chaque ID à son URL, son titre, la requête, l'heure UTC, l'empreinte du texte et le modèle.

Compréhension des données : portrait du corpus

50 050	0	6	5
lignes initiales	valeur manquante	thèmes	émotions

Contrôles réalisés

- Colonnes attendues présentes
- Textes et labels manquants contrôlés
- Validité des catégories vérifiée
- Doublons exacts détectés
- Longueurs et distributions décrites

Longueur des textes

Minimum : **32** caractères
Médiane : **57** caractères
Moyenne : **56,84** caractères
Maximum : **81** caractères

Exploration : les six thèmes

Part de chaque thème dans les 49 055 textes préparés



« Variation en fonction de quoi ? » — notre variable de comparaison est le thème (**topic**).

Exploration : les cinq émotions

Effectifs dans les 49 055 observations



Lecture descriptive

Chaque émotion représente environ **20 %** du corpus. Pour étudier les différences, nous croisons **topic × emotion**.

Les effectifs détaillés par couple sont fournis dans *croisement_theme_emotion.csv*.

Préparation : nettoyer puis partitionner



Découpage stratifié par thème et émotion · graine 42



Caractères arabes et emojis conservés · CSV en UTF-8 avec BOM

Résultat : un corpus prêt pour l'analyse

Ce que nous avons construit

- Un agent de recherche et d'annotation initiale
- Un schéma stable et documenté
- Un pipeline reproductible de nettoyage
- Trois partitions réutilisables pour le NLP

Suite logique

Entraîner un modèle de classification des émotions, l'évaluer sur le jeu de test, puis comparer ses résultats par thème.

Des pages Web aux données prêtes pour le NLP